

Modelo Preditivo para a Copa do Mundo FIFA 2026

Autores: Bruno Sampaio Silva
Levi Falcão de Queiroz
Moisés de Souza Oliveira
Saulo de Melo Ramos

Feira de Santana, 2026

Agenda

Mostrar as características mais relevantes e o pré-processamento dos dados. Abordar o treinamento e a avaliação do modelo preditivo. E pra finalizar, apresentaremos os resultados obtidos e as conclusões do projeto.

1. Introdução:

Apresentação do problema e do objetivo do projeto e o que foi feito até aqui

2. Exploração do Dataset:

- Análise da estrutura dos dados.
- tipos de atributos.
- agrupamento das informações.

3. Escolha das Características:

Seleção das variáveis para o treinamento do modelo.

4. Pré-Processamento:

Codificação de atributos categóricos e padronização dos dados.

5. Treinamento do modelo, Treino e Avaliação:

Configuração do algoritmo e definição dos hiperparâmetros. Divisão dos dados e análise das métricas de desempenho.

6. Resultados e Conclusão:

Apresentação dos resultados obtidos. Considerações finais do projeto.

Introdução

- Programa de Trainee da Dendê Softhouse;
- Modelagem Preditiva;
- Previsão de resultados da Copa do Mundo FIFA 2026.

unex



Anteriormente

- Biblioteca Statistic
- Análise Exploratória de Dados
- Pré-processamento
- Regras de Associação (FP-Growth)
- Preparação do Dataset



Anteriormente do projeto

Exploração do Dataset



- Registros: 250 e 1000
- Atributos: 25
- Variável alvo: winner
- Tipos de dados:
Numéricos e Categóricos
- Verificação de valores ausentes;
- Verificação de registros duplicados

Característica	Valor
Registros (treino)	1.000
Registros (teste)	250
Atributos	25
Variável Alvo	winner
Valores Ausentes	0
Duplicados	0

Tipos de Atributos



Atributos Numéricos:

- Ranking FIFA
- Gols marcados
- Gols sofridos
- Vitórias
- Participações em Copas

Atributos Categóricos:

- team_name
- country_code
- confederation

ATRIBUTOS NUMÉRICOS		
	Ranking FIFA Ranking Atual	1º 16º
		BRASIL ALEMANHA
	Gols Marcados Total	1682 1399
		BRASIL ALEMANHA
	Gols Sofridos Total	615 810
		BRASIL ALEMANHA
	Vitórias Total	654 570
		BRASIL ALEMANHA
	Participações em Copas Total	22/22 20/22
		BRASIL ALEMANHA

ATRIBUTOS CATEGÓRICOS		
Nome		
		
	Brasil	Alemanha
Código do País		
	BRA	GER
	Brasil	Alemanha
Confederação		
	CONMEBOL	UEFA
	Brasil	Alemanha

Atributos Numéricos e Categóricos

Escolha das Características



- Seleção dos atributos mais relevantes para a previsão.
- Remoção de informações sem impacto na classificação.
- Utilização de variáveis relacionadas ao desempenho das seleções.

Atributo	Usar?
FIFA Ranking	
Vitórias	
Gols Marcados	
Continente	
ID do Registro	
Nome do Arquivo	

Escolha das Características

Colunas escolhidas do Dataset

Grupo	Colunas	Motivo
Ranking FIFA	fifa_rank fifa_points	Nível da seleção
Desempenho recente	wins_last_10_matches losses_last_10_matches draws_last_10_matches win_rate_last_year recent_form_score	Momento da equipe
Ataque	goals_scored_avg shots_per_game shots_on_target_ratio	Eficiência em campo
Defesa	goals_conceded_avg clean_sheets_last_10	Nível técnico
Elenco / valor	avg_player_rating star_players_count market_value_million_eur experience_avg_caps coach_experience_years	Vivência competitiva
Estilo de jogo	possession_avg passing_accuracy	Organização tática
Fatores do torneio	host_advantage travel_distance_avg climate_similarity_score	Influência do ambiente
Categorica	confederation	Contexto regional

Escolha das Características

Mudança de Dimensão



Antes	Depois	Alteração
25 atributos	23 atributos	Redução de 2 atributos

Atributos removidos:

- team_name
- country_code

Motivo da remoção:


- não contribuíam com a previsão do vencedor por que elas não carregam informação preditiva.

Mudança de Dimensão

Pré-Processamento: Codificação dos Atributos

Atributos Categóricos

- Conversão de dados textuais para valores numéricos.




Atributos Numéricos

- Verificação e preparação dos valores para o treinamento do modelo.
- Padronização ou normalização (se utilizada).



Codificação dos Atributos

Codificação dos Dados Categóricos



Codificação dos Dados Categóricos

Tratamento de Dados Ausentes



Etapa	Método de Verificação	Resultado
Dados Ausentes	<code>df_treino.isnull().sum().sum()</code>	0 valores ausentes
Dados Duplicados	<code>df_treino.duplicated().sum()</code>	0 registros duplicados

Nenhuma coluna precisou de tratamento, pois o dataset não apresentava valores ausentes nem registros duplicados.

Tratamento de Dados Ausentes

Padronização dos Dados



Atributos Padronizados

fifa_points,
market_value_millio
n_eur

wins_last_10_matche
s, goals_scored_avg,
shots_per_game

experience_avg_caps,
coach_experience_ye
ars

travel_distance_avg

Técnica Utilizada: StandardScaler

- Aplicação do StandardScaler
- Variáveis na mesma escala
- Média = 0 e Desvio Padrão = 1
- Treinamento mais equilibrado

Padronização dos Dados

Algoritmo

- Logistic Regression

Como funciona?

- Analisa as características das seleções.
- Calcula a probabilidade de vitória.
- Classifica o resultado como vencedor ou não vencedor.

Por que escolhemos esse algoritmo?

- Simples de implementar;
- Eficiente para classificação;
- Gera probabilidades de previsão;
- Fácil interpretação dos resultados.

Algoritmo

unex

Seleção	Probabilidade de Vitória
Brasil	78%
França	65%
Japão	32%

Algoritmo



1 EU RECEBO OS DADOS

	BRASIL	
	Ranking FIFA	5
	Gols marcados (média)	2.10
	Gols sofridos (média)	0.80
	Forma recente (pontos)	8.30
	Valor do elenco (milhões €)	980
	Confederação	CONMEBOL

2 EU TRANSFORMO EM PONTOS (pesos aprendidos)

ATRIBUTO	PESO APRENDIDO	PONTOS
 Ranking FIFA (5)	+0.20	+1.00
 Gols marcados (2.10)	+0.40	+0.84
 Gols sofridos (0.80)	+0.50	+0.40
 Forma recente (8.30)	+0.30	+0.69
 Valor do elenco (980)	+0.60	+0.99
 Confederação (CONMEBOL)	+0.10	+0.10
TOTAL DE PONTOS		+4.02

Algoritmo

Algoritmo – Bias



Contribuições	+4.02
Bias	-2.50


$$4.02 - 2.50 = 1.52$$

PONTUAÇÃO INTERNA

1.52

Algoritmo

Algoritmo - Porcentagem



Exemplo

Seleção	Probabilidade de Vitória
Brasil	82%
França	65%
Japão	32%

Algoritmo

Biblioteca



- Scikit-learn

Por que escolhemos essa biblioteca?

- Fácil implementação;
- Ampla documentação e suporte da comunidade.
- Suporte para Hiperparâmetros

Biblioteca

Treinamento do Modelo



Item	Descrição
Algoritmo	Logistic Regression
Dados de Treino	1.000 registros
Dados de Teste	250 registros
Biblioteca	Scikit-learn
Objetivo	Aprender padrões para prever a variável winner

Treinamento do Modelo

Hiperparâmetros



C	Accuracy	F1-Score	ROC AUC
0.1	66,50%	63,45%	71,78%
1.0	67,20%	64,00%	71,54%
10.0	67,50%	64,51%	71,39%

Hiperparâmetros

Análise da Métrica de Desempenho



Accuracy:

- percentual de previsões corretas realizadas pelo modelo.

$$Acuracia = \frac{Previsoes\ Corretas}{Total\ de\ Previsoes}$$

F1-Score:

- equilíbrio entre precisão e recall, indicando a qualidade geral da classificação.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Análise da Métrica de Desempenho



Accuracy: $Acuracia = \frac{Previsoes\ Corretas}{Total\ de\ Previsoes}$

Métrica	Resultado	Interpretação
Accuracy	67,00%	Percentual de previsões corretas
F1-Score	64,13%	Equilíbrio entre precisão e recall

F1-Score: $F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$

Resultados



Modelo Utilizado:

- Logistic Regression
- Biblioteca: Scikit-learn

Principais Resultados:

- Modelo treinado com sucesso.
- Capacidade de prever a variável winner.
- Geração de probabilidades para as seleções.

Pos	Pais	Codigo	Probabilidade
1	Argentina	ARG	79.37%
2	Spain	ESP	79.36%
3	England	ENG	78.72%
4	France	FRA	74.83%
5	Brazil	BRA	72.40%
6	Croatia	CRO	65.86%
7	Morocco	MAR	63.97%
8	Netherlands	NED	63.76%
9	Portugal	POR	63.35%
10	USA	USA	62.72%

Resultados

Considerações Finais

- O modelo preditivo foi desenvolvido com sucesso.
- As etapas de análise e pré-processamento contribuíram para a qualidade dos dados.
- A Regressão Logística apresentou resultados para a classificação da variável winner.

unex



Considerações Finais